교차로 환경 분산 혼잡 제어를 위한 DQN 심층 강화학습 모델

최 윤 석[1)]

한양대학교 미래자동차공학과[1)]

DQN-Based Deep Reinforcement Learning Approach to Distributed Congestion Control in Intersection Environments

Yunseok Choi[1)]

[1)]*Department of Automotive Engineering, Hanyang University, Seoul 04673, Korea*

Abstract : This study investigates the generalization performance of a DQN-based transmission interval control model for V2X communication. The model is trained using highway PM traffic data from Olympic-Daero and evaluated in a crossroad environment modeled after Jangji-daero. Four reward structures (CBR-based, CBR+PDR-based, Hybrid, and Target-PDR-based) are compared to analyze their influence on congestion control behavior. Experimental results show that although the DQN policies learn consistent patterns in the highway scenario, all reward structures－including the Target-PDR reward－fail to adapt to the rapid density fluctuations of the crossroad environment, exhibiting nearly identical transmission patterns. This indicates that highway-only training is insufficient for generalization to complex urban intersections. The study highlights the need for environment-aware training and more expressive reward structures to enhance adaptability in real V2X congestion control.

Key words :Deep Reinforcement Learning(심층강화학습), V2X(차량 간 통신), Distributed Congestion Contorl(분산 혼잡제어), Channel Busy Ratio(채널 점유율), Packet Delivery Ratio(패킷 수신율), Transmission Interval Control(전송주기제어)

1. 서론(Introduction)

도심 교통량이 지속적으로 증가함에 따라 차량 간 통신(V2X)에서 채널 혼잡이 빈번하게 발생하고,[1)] 이로 인해 패킷 수신률(Packet Delivery Ratio, PDR)은 급격히 저하되며 채널 점유율(Channel Busy Ratio, CBR)은 상승하는 문제가 나타난다.[2)] 이러한 문제를 완화하기 위해 다양한 분산 혼잡 제어(Distributed Congestion Control, DCC) 기법이 제안되어 왔으며[3)], 그중 ETSI 표준 기반의 Rule-Based DCC는 단순성과 안정성을 바탕으로 널리 사용되고 있다. 그러나 ETSI DCC는 주로 유럽 고속도로와 같은 저밀도·고속 이동 환경을 기준으로 설계되었기 때문에[4)], 국내 도시형 교차로와 같이 교통 흐름 변화가 크고 차량 정체가 자주 발생하는 환경에서는 혼잡 제어 기준을 충분히 충족하지 못하는 한계가 존재한다. 실제로 올림픽대로 기반의 시나리오 분석에서도, 혼잡 제어 성능 차이가 PM 시간대(17–19시)에만 두드러지며 교차로·중밀도 환경에서는 적용성이 낮음을 확인할 수 있다.

이러한 배경에서 기존 Rule-Based 접근의 한계를 보완하기 위해, 다양한 환경 적응성을 갖춘 제어 기법에 대한 연구가 진행되고 있다. 그중 심층 강화학습(Deep Reinforcement Learning, DRL)은 환경 변화에 따라 정책을 스스로 조정할 수 있는 잠재적 장점을 지니고 있어[5)], 복잡한 혼잡 패턴을 보이는 도심 환경에서도 보다 유연한 제어가 가능할 것이라는 기대를 받고 있다. 그러나 학습 데이터와 정책이 특정 교통 구조(예: 고속도로 기반)로 편중될 경우, 새로운 도심 교차로와 같은 비정형 혼잡 환경에 일반

화하기 어렵다는 한계 역시 존재하며[6], 이러한 점은 실제 적용 가능성을 평가하는 데 중요한 고려 요소가 된다.

본 연구에서는 올림픽대로 PM 시간대 시나리오를 기반으로 학습된 DQN(Deep Q-Network) 모델을 장지대로 교차로 환경에 적용하여, Reward 설계(CBR 기반, CBR+PDR 기반, Hybrid, Target PDR 기반)에 따른 통신 성능 변화를 실험적으로 비교·분석한다. 이를 통해 고속도로에서 학습된 DRL 모델이 교차로 환경에서도 성능을 일반화할 수 있는지, 그리고 보상 구조가 혼잡 제어의 적응성에 어떠한 영향을 미치는지를 검증하는 것을 목표로 한다.

2. 관련 연구(Related Works)

2.1 V2X 통신과 혼잡 문제

차량 간 통신(Vehicle-to-Everything, V2X)은 자율주행 및 지능형 교통 시스템(ITS)의 핵심 기술로, 차량 - 차량(V2V), 차량 - 인프라(V2I), 차량 - 보행자(V2P) 등 다양한 형태의 통신 링크를 통해 주변 상황을 빠르게 공유함으로써 주행 안정성과 예측 가능성을 향상시키는 역할을 한다.

그러나 도심 지역처럼 차량 밀도와 교통 흐름 변화가 큰 환경에서는 무선 채널 자원에 대한 경쟁이 급격히 증가하며, 채널 점유율(Channel Busy Ratio, CBR)의 상승과 함께 패킷 수신률(Packet Delivery Ratio, PDR)의 하락이 빈번하게 발생한다.[7] 이러한 혼잡 문제는 차량 간 안전 메시지의 전송 지연과 누락으로 이어져 V2X 기반 주행 안정성에 중대한 영향을 미치므로, 효과적인 혼잡 제어 기술의 필요성이 지속적으로 제기되고 있다.

2.2 ETSI 분산 혼잡제어(DCC)의 구조와 한계

ETSI에서 제안된 Rule-Based DCC는 현재 가장 널리 활용되는 혼잡 제어 방식으로, 노드가 측정한 CBR 값을 기반으로 메시지 생성 주기(Tgen)를 계단식으로 조절하는 특징을 가진다.[8] CBR이 특정 임계값(예: 0.65)을 초과하면 전송 주기를 늘려 채널 점유율을 낮추고, 반대로 혼잡이 해소되면 전송 주기를 단축하는 형태로 동작한다. 이러한 방식은 구조가 단순하고 계산량이 적어 실시간 적용에 유리하다는 장점이 있다.

그러나 ETSI DCC는 주로 유럽 고속도로 환경을 기준으로 설계된 규격으로, 차량 흐름이 비교적 균일하고 밀도 변화가 완만한 상황을 전제로 한다. 이에 따라 국내 도심 도로 및 교차로처럼 밀도 변화가 크고 정체가 불규칙적으로 발생하는 환경에서는, ETSI가 제시하는 정적 CBR 임계값 기반 제어가 실제 혼잡 수준을 충분히 반영하지 못하는 한계가 존재한다.

실제로 본 연구의 올림픽대로 PM 시간대 분석 결과에서도, 특정 구간에서 혼잡이 매우 높을 때에만 DCC의 개입 효과가 일부 확인되었으며, 중밀도 혹은 비균일한 밀도 변화가 나타나는 구간에서는 ETSI 기준이 제대로 충족되지 않아 PDR 개선 효과가 제한적으로 나타났다. 즉, 본 연구에서 구성한 도심형 시나리오에서는 ETSI DCC가 의도한 혼잡 제어 기준이 환경 특성과 일치하지 않아 성능이 충분히 발휘되지 못한 것으로 볼 수 있다.

2.3 DRL 기반 V2X 통신 자원제어 연구 동향

최근에는 환경 변화에 따라 정책을 자동으로 조정할 수 있는 심층 강화학습(Deep Reinforcement Learning, DRL) 기반 혼잡 제어 기법이 활발히 연구되고 있다. DRL은 상태(State)와 보상(Reward)을 기반으로 최적 정책을 학습하는 방식으로, 도심 환경처럼 불확실성이 높고 비선형적인 동작이 요구되는 문제에서 특히 강점을 지닌다.

DQN(Deep Q-Network)은 이산형 행동 공간을 갖는 제어 문제에 적합하여 V2X 전송 주기(Tgen) 제어에 널리 적용되고 있으며, CBR·PDR과 같은 통신 성능 지표를 Reward Funciton에 직접 반영할 수 있다는 장점이 있다.

기존 연구에서는 주로 고속도로 기반 시나리오를 활용하여 DQN 기반 자원 제어 모델을 학습하였으며, 이를 통해 Rule-Based DCC보다 향상된 혼잡 제어 성능을 확인했다는 보고가 다수 존재한다.

3. 시뮬레이션 환경 구성 (Simulation Environment)

본 연구에서는 고속도로 환경에서 학습된 DQN 기반 분산 혼잡 제어(DCC) 모델의 교차로 환경 일반화 가능성을 평가하기 위해 실제 도로 지형을 반영한 시뮬레이션 환경을 구성하였다. 시뮬레이션은 SUMO와 WiLabV2XSim을 연동하는 방식으로 진행되었으며, 학습 환경과 테스트 환경을 각각 올림픽 대로 및 장지대로 교차로 시나리오로 구분하였다.

3.1 도로 네트워크 및 교통 시나리오

3.1.1 올림픽대로 고속도로 시나리오(학습 환경)

학습 환경은 서울 동부 지역의 주요 간선 도로인 올림픽대로 구간(강일IC->암사대교 남단)을 대상으로 구성하였다. 실제 지도를 기반으로 도로 형상을 추출한 후, 이를 SUMO(Simulation of Urban MObility) 시뮬레이터에서 사용할 수 있도록 네트워크 파일로 변환하였다.

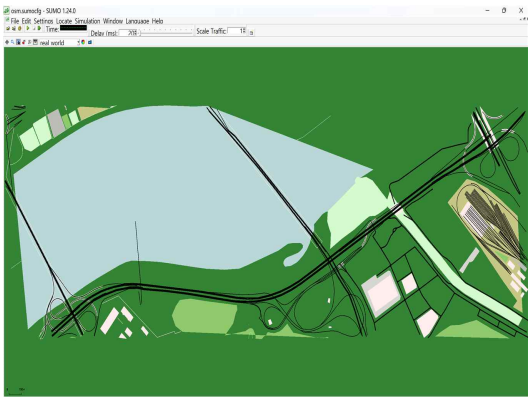

Fig. 1 SUMO 시뮬레이터상의 올림픽대로

교통량은 시간대별 혼잡 특성을 반영하기 위해 AM(07~09시), MID(12~14시), PM(17~19시) 세 구간으로 나누어 설정하였으며, 단위 시간당 차량 수(vehph, vehicles per hour)를 조절하여 각 시간대별 차량 밀도와 평균 속도가 실제 도로 상황과 유사하도록 설정하였다. 올림픽대로 시나리오에서 ETSI DCC 적용 여부에 따른 PDR, CBR 변화를 분석한 결과, AM과 MID 시간대에는 비교적 낮은 혼잡도로 인해 성능 차이가 거의 없었던 반면, PM 시간대에서만 PDR 저하 및 CBR 상승이 두드러지며 혼잡 제어 성능 차이가 뚜렷하게 나타났다. 이에 본 연구에서는 PM 시간대 데이터를 중심으로 학습용 데이터 셋을 구성하였다.

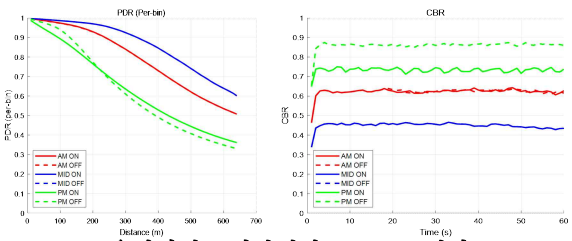

Fig. 2 올림픽대로 시간대별 PDR, CBR변화

3.1.2 장지대로 교차로 시나리오(테스트 환경)

테스트 환경은 도심 도로 구조에서의 DQN 기반 혼잡 제어 성능을 확인하기 위해 서울 송파구 장지대로 인근 교차로를 기반으로 구성하였다. 다만 본 연구의 목적은 교차로 자체의 복잡한 특성(정지-출발, queue형성, 밀도 클러스터링 등)을 정밀하게 재현하는 것이 아니라, 고속도로 환경과 구조가 다른 시나리오에서 학습된 정책의 일반화 성능을 평가하는 것에 있다. 따라서, 실제 장지대로보다는 단순화된 십자형(4-way)교차로 형태로 모델을 구성하였으며, 차량 밀도는 고속도로 환경(올림픽대로)과 비교가 가능하도록 조정하였고, 테스트 환경으로서의 기능만 수행하도록 최소한의 구조만 반영하였다.

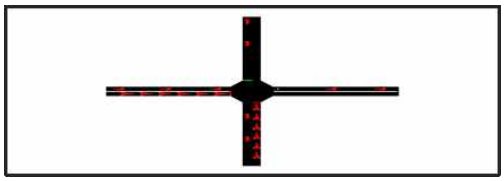

Fig. 3 SUMO 시뮬레이터에서의 십자교차로

3.1.3. 학습 환경(올림픽대로) 선정 배경

본 연구에서 올림픽대로 구간을 학습 환경으로 선정한 이유는, 해당 도로가 WiLabV2XSim에서 가정하는 도로 모델과 구조적으로 높은 정합성을 갖기 때문이다. WiLabV2XSim은 기본적으로 신호등이 존재하지 않고, 램프 진입·유출에 의한 복잡한 병합·분기 흐름이 없는 직선형 고속도로 구간을 전제로 하여 차량 이동과 V2X 통신 혼잡을 모사한다. 이는 차량이 연속적으로 주행하며, 정지 - 출발이 반복되는 교차로 기반 패턴이 없다는 특징을 가진다. 올림픽대로는 이러한 시뮬레이터의 전제 조건과 일치하는 단일 방향성·신호등 비존재·직선 기반 도시 고속화도로로 구성되어 있어, 차량 흐름이 비교적 단순하고 혼잡 변화가 명확하게 나타난다. 따라서 DCC 성능 분석에 필요한 밀도 - CBR - PDR 관계를 안정적으로 추출할 수 있는 환경으로 적합하며, DQN 기반 혼잡 제어 모델의 학습 데이터 셋을 구축하기에 가장 적절한 도심형 고속도로 시나리오로 판단된다.

3.2 V2X 통신 시뮬레이션 환경

본 연구에서는 차량 간 패킷 송수신, 채널 혼잡도, 링크 성능을 정량적으로 평가하기 위해 WiLabV2XSim 기반의 V2X 통신 시뮬레이터를 활용하였다.

WiLabV2XSim은 Todisco et al.(2021)에서 제안한 5G-V2X Sidelink 오픈소스 시뮬레이터 구조를 기반으로 확장된 구조를 가지지만,[9] 실제 통신 모델은 LTE-V2X Mode 4 규격의 SB-SPS(Sensing Based

Semi-Persistent Scheduling) 자원 선택 방식을 따른다. 즉, 본 연구의 시뮬레이션 환경은 NR-V2X 기능이 아닌 3GPP LTE-V2X Mode 4 표준(TR 36.885)에 명시된 분산형 자원 할당 메커니즘을 중심으로 동작한다. Mode 4는 기지국 지원 없이 차량이 스스로 자원을 선택하는 완전 분산형 자원 선택 방식으로, 혼잡 상황에서의 자원 중복(Collision) 및 채널 점유율(CBR) 변화가 통신 성능(PDR)에 크게 영향을 미친다. WiLabV2XSim은 이러한 Mode 4의 핵심 동작을 그대로 구현하여, 높은 차량 밀도 환경에서의 CBR – PDR 상관성을 정확하게 모사할 수 있다.

시뮬레이션에서 사용한 통신 파라미터(메시지 크기 300 Bytes, 대역폭 10MHz, 최소 전송 주기(Tgen = 100ms 등)는 3GPP TR 36.885 및 관련 LTE-V2X 연구(Molina-Masegosa & Gozálvez, Bazzi et al.)에서 제시한 기준을 따랐다.[10] WiLabV2XSim은 각 타임슬롯에서 SINR 기반 패킷 수신 여부를 판단하고, 채널이 busy 상태로 판정된 비율(CBR)을 계산하여, 차량 밀도 변화에 따른 통신 성능 곡선(PDR – CBR)을 생성한다. 이러한 지표는 본 연구의 DQN 기반 DCC 학습과 교차로 테스트 환경 평가에 필요한 상태(state) 및 보상(reward)을 구성하는 핵심 데이터로 활용되었다.

3.3. 학습 및 테스트용 데이터 셋 구성

앞서 설명한 올림픽대로 PM 시간대 시나리오를 기반으로, 차량 밀도 구간별로 시뮬레이션을 수행하여 전송 주기(Tgen) 설정에 따른 PDR 및 평균 CBR을 집계하였다. 각 밀도 구간에서 충분한 시간 동안 시뮬레이션을 반복 수행한 뒤, 수신 성공 패킷 수와 전송 패킷 수의 비율로 PDR을, 채널이 busy 상태인 시간 비율로 CBR을 계산하여 정리하였다. 이렇게 생성된 밀도 – PDR – CBR 데이터는 이후 DQN 학습 과정에서 상태(State)와 보상(Reward)을 구성하기 위한 기초 데이터 셋으로 사용된다.

테스트용 데이터 셋은 장지대로 교차로 시나리오에서 동일한 통신 파라미터를 적용하되, 신호 주기 및 차량 유입 패턴으로 인해 발생하는 밀도·CBR·PDR 변화를 기록하는 방식으로 구성하였다. 이후 학습된 DQN 모델을 교차로 환경에 적용하고, 각 보상 설계(CBR 기반, CBR+PDR 기반, Hybrid, Target PDR 기반)에 대해 PDR 곡선, CBR 곡선 및 전송 주기 선택 패턴을 비교·분석함으로써, 고속도로 – 교차로 간 환경 차이가 DQN 기반 DCC 성능에 미치는 영향을 평가하였다.

4. DQN 기반 모델 설계

본 연구에서는 차량 밀도 및 채널 혼잡도 변화에 따라 전송 주기(Tgen)를 적응적으로 조정하는 정책을 학습하기 위해 DQN(Deep Q-Network) 기반의 강화학습 모델을 사용하였다.[11] DQN은 상태 – 행동 공간이 비교적 단순하고 전송 주기와 같은 이산적 제어 문제에 적합하여 V2X 통신에서의 분산혼잡제어(DCC) 정책 학습에 널리 활용되는 기법이다.

DQN은 기본적으로 Q-learning을 심층신경망과 결합하여 상태 – 행동값(Q-value)을 근사하는 방식이며, 경험 재현(experience replay)과 타깃 네트워크(target network) 구조는 학습 안정성을 보장하는 데 중요한 역할을 한다.[12] 이러한 학습 안정화 기법은 원래 고차원 비디오 입력을 다루기 위해 도입되었으나, 상태 변화가 천천히 일어나고 데이터 상관성이 높은 통신 환경에서도 효과적인 특성을 제공한다.

본 연구의 목적은 DQN 구조 자체를 제안하는 것이 아니라, 보상 설계에 따라 정책 특성과 일반화 성능이 어떻게 달라지는지 분석하는 데 있다.

따라서 신경망 구조나 하이퍼파라미터는 Open-source WiLabV2XSim 및 기존 DQN 기반 DCC 연구에서 활용되는 표준 구성을 따르며,[8),9),10),11] Reward Function의 차이에 따른 정책 선택 경향성과 교차로 환경 적응력을 중점적으로 비교하였다.[5),6),7]

4.1 상태(State) 정의

본 연구의 상태 공간은 차량 밀도(ρ) 와 평균 채널 점유율(CBR) 두 가지 지표로 구성하였다.

1) 차량 밀도(ρ)

차량 밀도는 채널 사용량과 혼잡도에 직접적인 영향을 미치는 핵심 환경 변수이다. 또한 고속도로와 교차로 환경에서 동일한 밀도라 하더라도 CBR의 곡선 특성이 서로 다르기 때문에, 정책의 일반화 성능을 평가하기 위한 필수적인 요소로 활용된다.

2) 평균 CBR(Channel Busy Ratio)

CBR은 DCC에서 혼잡 정도를 판단하는 가장 중요한 지표이며, ETSI DCC에서 제시하는 임계값(0.65)을 기준으로 혼잡 여부가 결정된다. 본 연구에서는 학습 데이터 셋에서 차량 밀도별로 추

출한 평균 CBR 값을 상태 변수로 사용하여, 모델이 혼잡 상황에서 전송 주기(Tgen)를 줄이거나 증가시키는 구조를 학습할 수 있도록 구성하였다.

따라서 상태 벡터는 다음과 같이 정의된다.

$$s_t = [\rho_t, CBR_t]$$

4.2 행동(Action) 정의

행동 공간은 차량이 선택할 수 있는 전송 주기(Tgen)로 구성되며, 총 3개의 이산값을 사용하였다.

A={100ms,200ms,300ms}

이는 기존 ETSI DCC의 전송 주기 단계와 동일한 범위이며, 높은 빈도(100 ms), 중간 빈도(200ms), 낮은 빈도(300ms)로 구성되어 있다.

4.3 보상(Reward) 설계

본 연구에서는 보상 구조가 정책 행동 특성에 미치는 영향을 확인하기 위해, 서로 다른 기준을 반영한 네 가지 보상 구조(CBR 기반, CBR+PDR 기반, Hybrid, Target PDR 기반)를 구성하였다.

각 Reward의 정의는 <Table 1>에 제시하였으며, 본 연구에서는 동일한 DQN 구조에서 보상만 변경하여 정책의 선택 경향, 안정성, 환경 일반화 성능의 차이를 분석하였다.

State	rho(차량밀도), avgCBR
Action	T_{gen}=100ms, 200ms, 300ms
Reward	I) $-(\mathrm{avgCBR}-0.7)^2$
	II) 0.7 * PDR- 0.3 *avgCBR
	III) 0.7 * PDR-0.3*avgCBR-0.2*|ΔPDR|
	IV)-1000*|PDR-PDR_{Target}|(PDR_{Target} = 0.85)

Table1. DQN Reward Function 설계

4.4 학습 절차 개요

학습은 올림픽대로 PM 시간대(고속도로 환경)에서만 수행되며, DQN은 상태(ρ, CBR)를 입력받아 전송 주기를 선택하고, 보상에 따라 Q 값을 업데이트하는 방식으로 정책을 학습한다. Replay buffer, ε-greedy 탐색, target network 등 DQN의 표준 구성 요소는 기존 연구의 일반적인 설정을 그대로 사용하였다. 학습이 완료되면, 교차로 환경(장지대로)에 동일한 모델을 적용하여 학습되지 않은 환경에서의 정책 일반화 성능을 평가하였다.

5. 시뮬레이션 결과

본 장에서는 올림픽대로 PM 시간대 기반으로 학습된 DQN 모델의 보상 구조별 학습 특성과, 학습된 모델을 교차로 환경(장지대로)에 적용했을 때의 테스트 결과를 제시한다. 분석은 (1) Non-target 기반 Reward 학습 결과, (2) Target 기반 Reward 학습 결과, (3) 교차로 테스트 결과의 세 단계로 구성하였다.

5.1 Non-target 기반 Reward 학습 결과

본 연구에서 사용한 세 가지 Non-target 기반 Reward(CBR,CBR+PDR,Hybrid)는 Fig.4~Fig.6에서 확인되듯이 모두 특정 전송 주기(주로 200ms 또는 300ms)에 정책이 수렴하는 공통적 경향을 보였다. 이는 해당 Reward 들이 CBR, PDR, ΔPDR과 같은 상대적 지표만을 반영하고 있기 때문에, 서로 다른 혼잡 상황을 세밀하게 구분하여 조절하기보다는 하나의 일관된 행동을 강화하는 방향으로 학습이 이루어진 결과로 해석된다. 또한 차량 밀도가 증가하는 구간에서는 모든 모델에서 PDR의 급격한 하락과 CBR의 상승이 동시에 나타났으며, 이는 Non-target Reward 기반 모델이 혼잡 레벨 변화에 대해 충분히 민감하게 반응하지 못한다는 점을 의미한다. 주기 선택의 다양성도 전반적으로 낮아, 밀도 변화에 따른 전송 주기 조절 능력 역시 제한적인 것으로 나타났다.

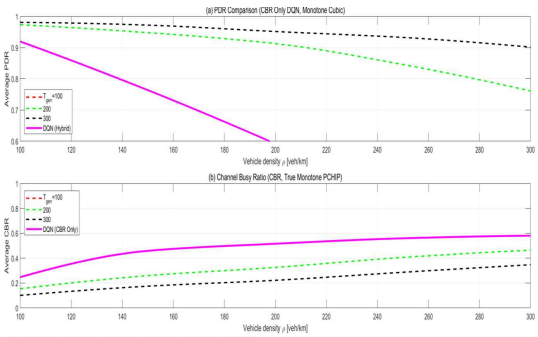

Fig. 4 CBR 기반 Reward 학습 결과

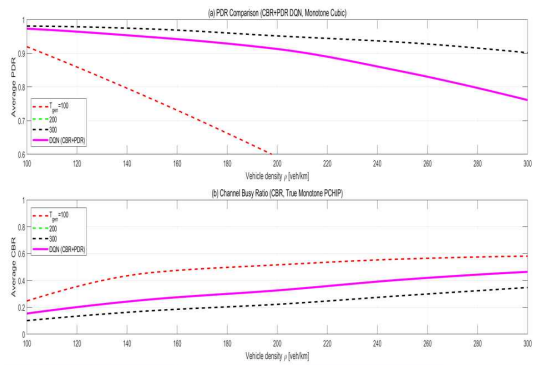

Fig. 5 CBR +PDR 기반 Reward 학습 결과

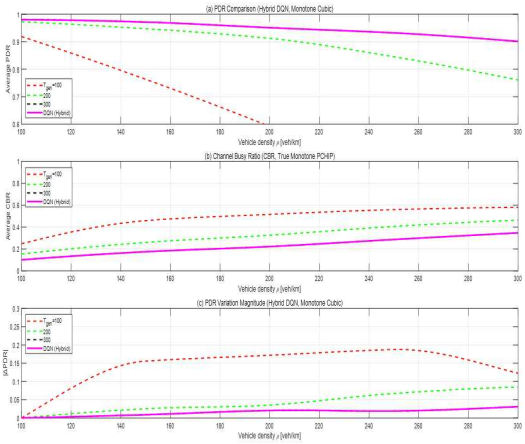

Fig. 6 Hybrid(CBR+PDR+ ΔPDR) Reward 학습 결과

5.2 Target 기반 Reward 학습 결과

Target 기반 Reward는 Non-target Reward와 비교했을 때 학습 과정에서 가장 뚜렷한 적응적 제어 특성을 보였다. Fig.7에서 나타나듯이, Target Reward 모델은 목표 PDR(PDR_target = 0.85)에 접근하기 위해 전송 주기를 지속적으로 조정하며, Non-target Reward에서 관찰된 특정 전송 주기 고정 현상이 나타나지 않았다.

이는 Target Reward가 절대적 목표 기반의 보상 구조를 사용하기 때문에 목표값과의 오차를 줄이는 방향으로 행동을 적극적으로 변화시키며, 학습 환경에서도 일정 수준의 적응적 제어가 성공적으로 이루어졌음을 의미한다.

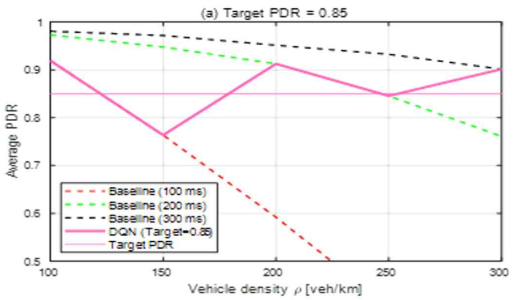

Fig.7 Target 기반 Reward 학습 결과

5.3 교차로 테스트 결과

교차로 환경에서 평가한 결과, Non-target Reward 기반 모델뿐 아니라 Target Reward 기반 모델 역시 기대했던 것처럼, 전송 주기 조절을 상황에 맞게 조절하지 못하고, 시뮬레이션 전반에 걸쳐 두 방식 모두 거의 특정 전송 주기에 고정된 형태의 정책을 유지한다는 사실을 확인하였다.

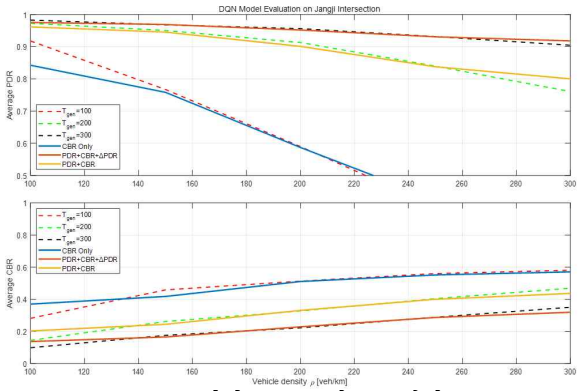

Fig.8 Non-Target 기반 Reward 테스트 결과

Fig.8과 Fig.9에서 보다시피, 교차로의 급격한 밀도 변동 구간에서도 Target 기반 Reward 모델은 목표 PDR 기반의 적응적 조절을 수행하지 못하였고, 그 결과 PDR 및 CBR 곡선 또한 Non-target Reward 모델과 매우 유사한 형태로 나타났다. 즉, Target Reward는 학습 단계에서는 목표값을 활용한 미세한 조절 시도가 존재했지만, 교차로와 같은 비정형 환경에서는 실제 적응적 제어로 이어지지 않아 Non-target Reward와 동일한 한계를 보였다.

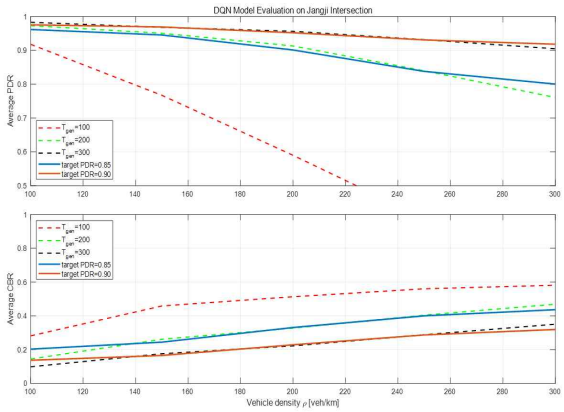

Fig.9 Target 기반 Reward 테스트 결과

6. 결론(Conclusion)

본 연구에서는 실제 고속도로 기반 시나리오를 이용하여 DQN 기반 전송 주기 제어 정책을 학습하고, 이를 교차로 환경에 적용함으로써 보상 구조에 따른 정책 행동 특성과 일반화 성능을 분석하였다. 네 가지 보상 구조(CBR 기반, CBR+PDR 기반, Hybrid, Target PDR 기반)를 각각 학습한 뒤, 학습 환경(올림픽대로 PM)과 테스트 환경(장지대로 교차로)의 통신 성능(PDR, CBR)과 전송 주기 선택 패턴을 비교하였다.

학습 결과, Non-target Reward(CBR, CBR+PDR,

Hybrid) 기반 모델은 모두 특정 전송 주기에 수렴하는 공통된 패턴을 보였으며, 밀도 변화에 따른 적응적 조절 능력이 제한적이었다. Target Reward는 목표 기반의 조절 시도가 일부 관찰되었으나, 고속도로 PM의 높은 혼잡 구간에서는 목표 PDR에 도달하기 어려워 결과적으로 비슷한 수렴 패턴을 보였다. 특히 교차로 테스트에서는 Target Reward 역시 Non-target Reward와 거의 동일한 정책을 유지하여, 네 보상 구조 모두 교차로의 비정형 혼잡 패턴을 반영한 적응적 제어를 수행하지 못하였다.

이러한 결과는 고속도로 기반 학습만으로는 교차로와 같은 급격한 밀도 변동 환경을 일반화하기 어렵다는 점을 보여주며, 보상 구조의 복잡성만으로는 환경 차이를 극복할 수 없음을 의미한다.

7. 후기

나는 3학년 2학기부터 CAM LAB에서 학부 연구생으로 참여하기 시작했다. 연구실에 들어오게 된 가장 큰 계기는, 이전부터 통신 분야에 관심이 있었고 실제 연구 환경에서 통신 문제를 깊이 다뤄보고 싶다는 생각이 들었기 때문이다. 연구를 시작한 이후로 V2X, 무선 자원 관리, 강화학습 기반 제어 등 다양한 통신 기술을 접할 수 있었고, 이번 종합설계 역시 이러한 관심의 연장선에서 진행되었다.

연구를 수행하면서 통신 시스템이 단순한 신호 전달이 아니라, 환경 변화에 적응하고 자원을 효율적으로 분배하는 매우 다층적인 문제임을 깨닫게 되었다. 특히 이번 연구에서는 고속도로 기반 정책을 교차로 환경에 적용하는 과정에서, 환경적 차이가 정책의 일반화 성능에 큰 영향을 미친다는 점을 직접 확인할 수 있었다. 이러한 경험은 내가 앞으로 어떤 연구를 하고 싶은지 스스로 방향성을 정하는 데에도 많은 도움을 주었다.

현재 나는 여러 통신 분야를 탐색하고 있지만, 그 중에서도 로봇 군집 통신(swarm communication) 분야가 가장 큰 흥미를 주고 있다. 단일 차량이나 로봇의 제어를 넘어서, 여러 개체가 서로 정보를 교환하며 집단적으로 협력하는 시스템은 통신·제어·지능의 모든 요소가 결합된 분야이기 때문에 매우 매력적이라고 느낀다. 이번 V2X 기반 분산 혼잡 제어 연구는 기술적 관점뿐 아니라 연구자로서 나의 진로 방향을 정하는 데에도 중요한 계기가 되었고, 앞으로 로봇 군집 통신과 같이 더욱 복잡한 다중 에이전트 환경에서의 통신 문제를 탐구해 보고 싶다는 확신을 갖게 해주었다.

이번 연구에서 아쉬웠던 점도 있다. 학습 데이터의 밀도 구간이 충분히 다양하지 못했고, 특히 올림픽대로 시나리오를 구성할 때 서울교통공사의 시간대별 평균 차량 진입률을 그대로 사용해야 했다는 점이 가장 크게 아쉬웠다. 이러한 평균값 기반 모델은 고속도로의 전반적 흐름을 반영하는 데는 도움이 되었지만, 특정 시점의 실제 진입률 변화나 돌발 혼잡 상황과 같은 세밀한 패턴을 구현하기에는 한계가 있었다. 실제 순간 밀집도나 교차류 증가가 반영된 데이터가 있었다면, PM 시간대뿐 아니라 다른 시간 구간에서도 혼잡을 보다 현실적으로 재현할 수 있었을 것이고, 그에 따라 DCC의 성능 차이도 더 명확하게 드러났을 것이라고 생각한다. 이러한 데이터의 부재는 이번 연구의 분석 정밀도를 제한한 요소였지만, 동시에 향후 연구에서 더 정교한 데이터 기반 시나리오를 구축하고 싶다는 동기 부여가 되었다.

이번 연구는 통신 분야에 대한 나의 관심을 더욱 확고하게 만들어주었고, 앞으로의 진로를 결정하는 데 중요한 경험이 되었다고 생각한다. 연구를 통해 얻은 고민과 아쉬움은 앞으로 내가 어떤 방식으로 연구를 설계하고 데이터를 다루어야 하는지에 대한 기준이 되어줄 것이라 믿는다.

References

1) Sepulcre, M., Mittag, J., Santi, P., Hartenstein, H., & Gozalvez, J. (2011). Congestion and awareness control in cooperative vehicular systems. Proceedings of the IEEE, 99(7), 1260-1279

2) Autolitano, A., Reineri, M., Scopigno, R. M., Campolo, C., & Molinaro, A. (2014, November). Understanding the channel busy ratio metrics for decentralized congestion control in VANETs. In 2014 International Conference on Connected Vehicles and Expo (ICCVE) (pp. 717-722). IEEE.

3) A. Festag, "Cooperative intelligent transport systems standards in europe," in IEEE Communications Magazine, vol. 52, no. 12, pp. 166-172, December 2014

4) Balador, A., Cinque, E., Pratesi, M., Valentini, F., Bai, C., G□mez, A. A., & Mohammadi, M. (2022). Survey on decentralized congestion control methods for vehicular communication. Vehicular Communications, 33, 100394.

5) Ye, H., Li, G. Y., & Juang, B. H. F. (2019). Deep reinforcement learning based resource allocation for V2V communications. IEEE Transactions on Vehicular Technology, 68(4), 3163-3173.

6) Yoon, Y., Lee, H., & Kim, H. (2023). Deep reinforcement learning-based dual-mode congestion control for cellular V2X environments. Electronics Letters, 59(20), e12984.

7) Hwang, J., & Lee, S. (2020). Balancing power and rate control for improved congestion control in cellular V2X communication environments. IEEE International Conference on Information and Communication Technology Convergence (ICTC), 469-474.

8) European Telecommunications Standards Institute. (2021). ETSI TS 103 574 V1.1.1: Intelligent Transport Systems (ITS); LTE-V2X; Distributed Congestion Control (DCC) framework. ETSI.

9) Todiscco, V., Bartoletti, S., Campolo, C., Molinaro, A., Berthet, A. O., & Bazzi, A. (2021). Performance analysis of sidelink 5G-V2X Mode 2 through an open-source simulator. IEEE Access, 9, 145648-145661.

10) 3rd Generation Partnership Project. (2020). 3GPP TR 36.214 V18.0.0: Evolved Universal Terrestrial Radio Access (E-UTRA); Physical layer measurements. 3GPP.

11) Mnih, V., Kavukcuoglu, K., Silver, D., Graves, A., Antonoglou, I., Wierstra, D., & Riedmiller, M. (2013). Playing atari with deep reinforcement learning. arXiv preprint arXiv:1312.5602.

12) Liu, M., Quan, W., Yu, C., Zhang, X., & Gao, D. (2021, September). Deep reinforcement learning based adaptive transmission control in vehicular networks. In 2021 IEEE 94th Vehicular Technology Conference (VTC2021-Fall) (pp. 1-5). IEEE.