# 교차로 환경 분산혼잡제어를 위한 DQN 심층강화학습 모델

한양대학교 미래자동차공학과
4학년: 최윤석
지도교수: 조한신

## 연구 배경 및 연구 목적

### ➢ 연구 배경

- 차량이 몰리는 도심 환경에서는 채널 혼잡으로 인해 통신 성능이 급격히 떨어지므로, 이를 완화하기 위해 분산혼잡제어(DCC)가 필요
- ETSI 표준 기반의 Rule-Based DCC는 유럽 고속도로를 기준으로 설계되어, 국내 도시형 교차로나 중밀도 환경에서는 혼잡 제어 기준을 충족하지 못함

### ➢ 연구 목적

- 고속도로 환경에서 학습된 DQN 모델을 교차로 시나리오에 적용하여 CBR·PDR 기반 보상 구조의 성능을 비교·분석함
- Reward 구성에 따른 PDR·CBR 지표 변화를 확인하여, 도로 환경 간 성능 일반화 가능 여부 검증

## 학습 환경

### ➢ 학습 환경 생성

실제 올림픽대로 지도 → SUMO 시뮬레이터상의 올림픽대로(강일IC->암사대교 남단)

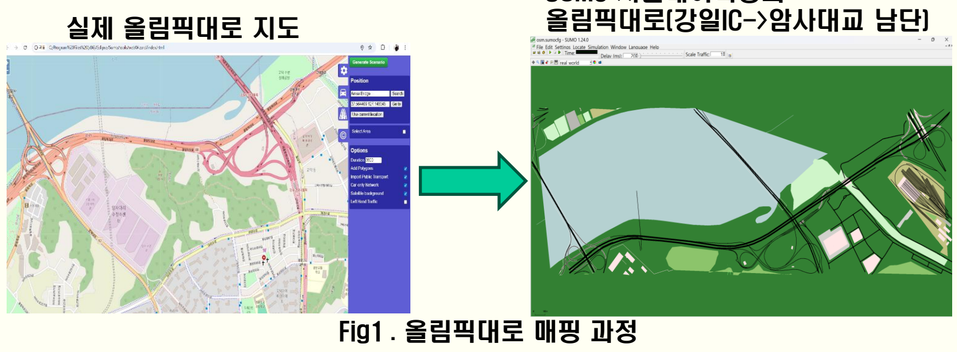

Fig1 . 올림픽대로 매핑 과정

- 올림픽대로의 실제 지형 데이터를 기반으로 SUMO 시뮬레이터에서 도로 네트워크를 구축
- 차량 진입률(vehph)을 시간대별로 달리 설정하여 AM, MID, PM 시나리오를 구성 *vehph:단위 시간당 지나간 차량 수

### ➢ 학습환경 분석 및 학습용 데이터 생성

*PDR:패킷 수신률, CBR:채널 혼잡도
**AM:07~09시, MID:12~14시, PM: 17~19시

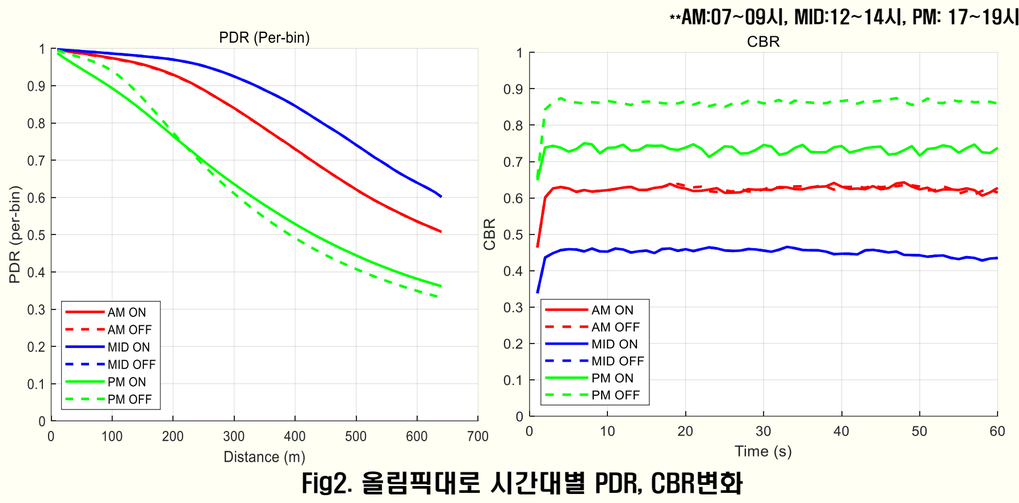


Fig2. 올림픽대로 시간대별 PDR, CBR변화

- ETSI DCC를 적용했을 때와 적용하지 않았을 때의 성능 차이가 PM(17~19시) 시간대에서만 명확하게 발생
- PM 시간대 (17~19시) 의 올림픽대로 시나리오 데이터를 학습용으로 활용

## DQN 알고리즘 Reward별 설계

Table1. DQN Reward Function 설계

| | |
|---|---|
| State | rho(차량밀도), avgCBR |
| Action | $T_{gen}$=100ms, 200ms, 300ms |
| Reward | I) $-(\mathbf{avgCBR}-0.7)^2$ |
| | II) 0.7 * PDR- 0.3 *avgCBR |
| | III) 0.7 * PDR-0.3*avgCBR-0.2*\|ΔPDR\| |
| | IV) -1000*\|PDR-$PDR_{Target}$\|($PDR_{Target}=0.85$) |

- 차량 밀도와 평균 CBR을 state로, 전송 주기($T_{gen}$)를 Action으로 설정하여 교통 흐름 변화와 채널 혼잡도를 직접 반영하도록 구성
- Reward는 I) 채널 혼잡도(CBR) 안정화, II) 패킷 수신율(PDR) 향상과 CBR 균형 유지, III) PDR 변화율까지 고려한 hybrid 보상, IV)는 목표 신뢰도 기준을 반영한 target PDR 기반 보상으로 세부적으로 설계함
- Rule-based ETSI DCC의 고정적 한계를 보완하기 위해, Reward 항목을 CBR→PDR→ΔPDR 순으로 확장한 후, target PDR 기반 Reward를 추가하여 목표 통신 신뢰도 수준을 직접 달성하도록 학습을 유도

## 학습 결과 분석

Fig3. CBR 기반 Reward 학습결과

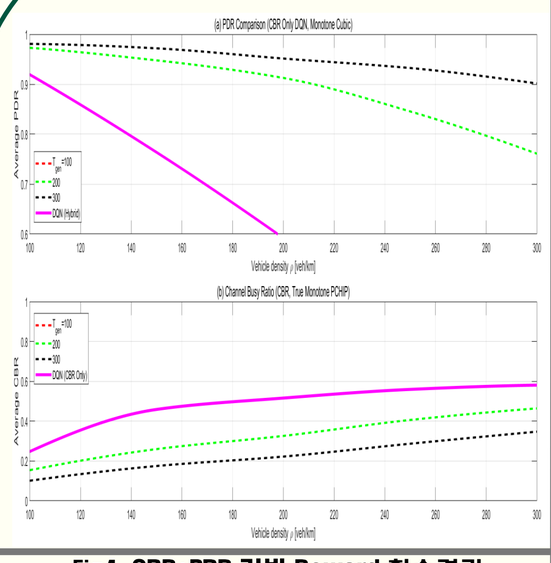

Fig5. Hybrid Reward (PDR + CBR + ⊿PDR) 학습결과

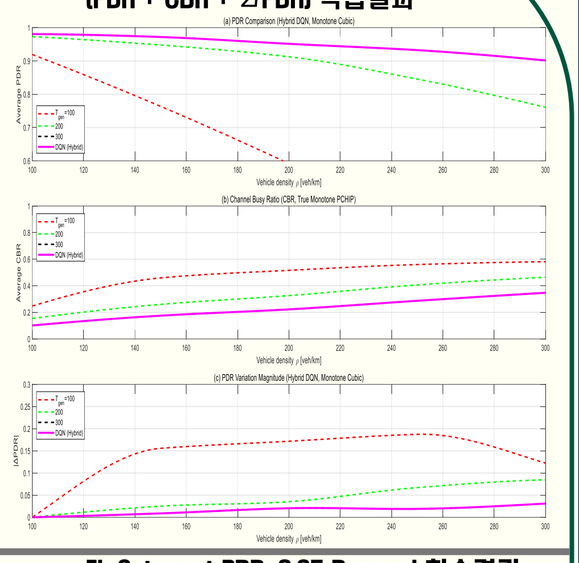

Fig4. CBR+PDR 기반 Reward 학습결과

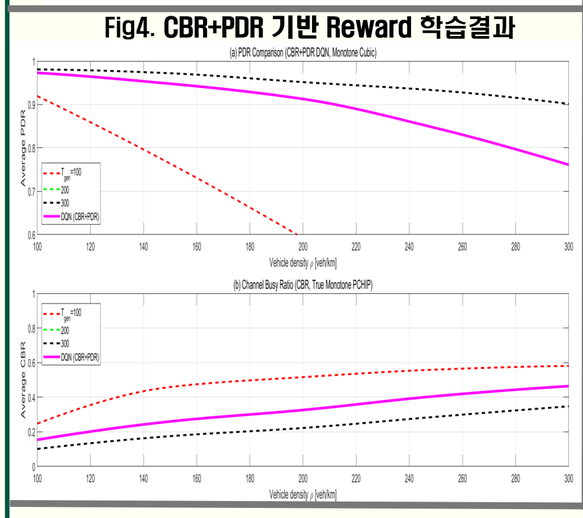

Fig6. target PDR=0.85 Reward 학습결과

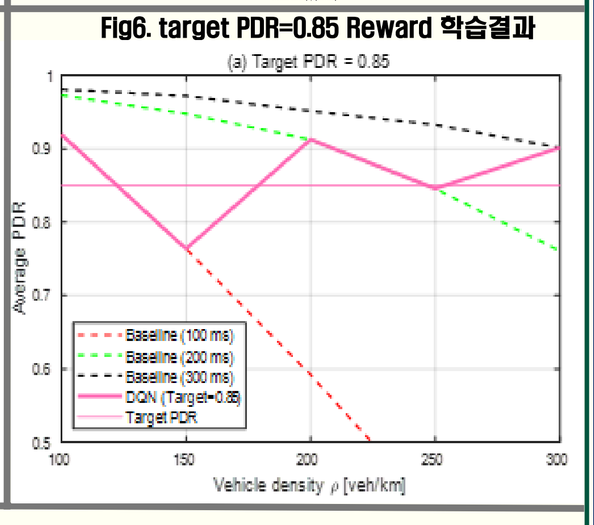


### ➢ Non-target 기반 Reward<Fig3/Fig.4/Fig.5>

- 상대적 지표(CBR, PDR, ΔPDR)의 변화를 기준으로 학습이 진행되었으며, 전반적으로 주기 선택은 각각의 reward별로 특정 주기에만 집중되는 경향이 나타남.
- 밀도 변화에 따른 적응 제어가 제한적이며, 다양한 혼잡 상황을 세밀하게 구분하며 반응하기에는 유연성이 부족함.

### ➢ Target PDR 기반 Reward<Fig.6>

- 모델이 목표 PDR(0.85) 을 유지하기 위해 적응적으로 전송 주기를 조절함이 확인됨
- 즉, 앞선 3가지 종류의 Reward와 달리 절대적 성능 기준을 명시적으로 부여했을 때, 본 모델은 혼잡도 변화와 정책 환경을 명확히 구분하며 대응하는 특성을 보임.

## 테스트 환경 생성 및 테스트 결과

### ➢ 테스트 환경 생성

실제 장지대로 교차로 지도 → SUMO 시뮬레이터에서의 교차로

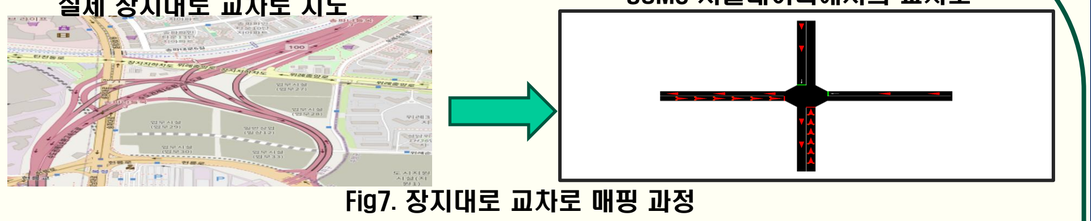

Fig7. 장지대로 교차로 매핑 과정

- 올림픽대로 환경 데이터를 기반으로 학습된 모델들을 바탕으로 테스트 환경을 장지대로 교차로 환경으로 설정한 후, SUMO 시뮬레이터를 활용하여 장지대로 교차로를 매핑

### ➢ 테스트 결과 분석

Fig8. Non-Target기반 Reward 테스트 결과

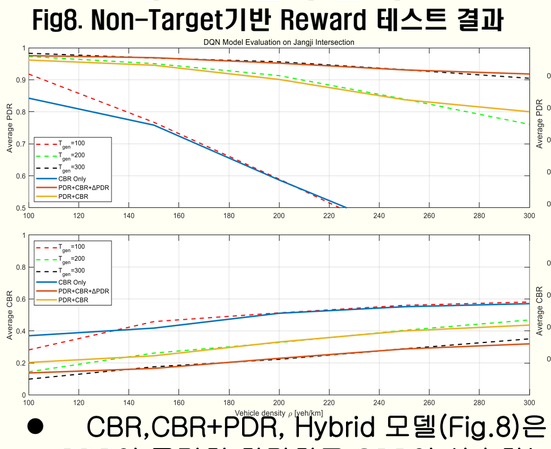

Fig9. Target기반 Reward 테스트 결과

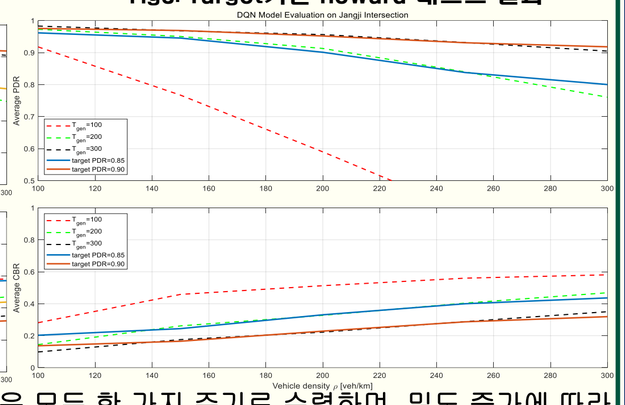

- CBR,CBR+PDR, Hybrid 모델(Fig.8)은 모두 한 가지 주기로 수렴하며, 밀도 증가에 따라 PDR이 급격히 하락하고 CBR이 상승하는 공통적인 경향을 보임
- 절대적 목표를 부여한 Target PDR Reward 모델(Fig.9) 역시 교차로 환경에서는 목표 신뢰도에 도달하지 못하고, 앞선 기존 모델들과 유사한 고정 주기 정책을 보임

## 연구 고찰

- **의의**: DRL 기반 DCC의 보상 설계에 따른 통신 성능 지표 변화를 고속도로 환경을 바탕으로 학습된 신경망을 교차로 환경으로 바꾸어 실험적으로 검증함.
- **한계**: 절대 보상 구조(Target PDR기반 Reward) 적용에도 불구하고 교차로에서는 목표하는 값에 수렴하지 못함. 이는 학습 환경과 교차로 환경의 구조적 차이에서 비롯됨.
- **개선 방향**:신호 주기·정지 시간 등 교차로 특성을 반영한 환경 적응형 학습 모델 확장 필요